1 Deep Q Network の擬似コード

以下, Deep Q Network の擬似コード.

```
Algorithm 1 Deep Q-learning with experience replay
Input: r_{\text{learn}}, n_{\text{rmem}}, \epsilon_{\text{init}}, \epsilon_{\text{final}}, l_{\text{expl}}, n_{\text{rpstart}}, f_{\text{learn}}, f_{\text{update}}, \gamma, n_{\text{batch}}, T
  1: Replay Memory D を初期化
 2: Q-Network Q をランダムな重み \theta で初期化
 3: Target network Q^- を重み \theta^- = \theta で初期化
 4: t = 1
 5: while t < T do
        while not done do
            \epsilon -greedy に従って行動 a_t を選択
 7:
            行動 a_t を実行し、報酬 r_t と次の画面 x_{t+1} と done を観測
 8:
            前処理して次の状態 S_{t+1} を生成
 9:
            Dに (s_t, a_t, r_t, s_{t+1}, done) を追加,|D| > n_{nmem} なら古いものを削除する.
10:
           if t > n_{\text{rpstart}} then
11:
               \epsilon = \max{(\epsilon_{\text{final}}, \epsilon - \frac{\epsilon_{\text{init}} - \epsilon_{\text{final}}}{l_{\text{expl}}})} \rightarrow \epsilon を線形減少
12:
               if (t-1)\% f_{learn} = 0 then
13:
                  D からランダムに (s_i, a_i, r_i, s_{i+1}, done) を n_{\text{batch}} 個の履歴をサンプル
                 y_{j} = \begin{cases} r_{j} & (done) \\ r_{j} + \gamma \max_{a'} Q^{-}(s_{j+1}, a'; \theta^{-}) & (otherwise) \end{cases}
                                                                 (done)
15:
                  \theta を y_i – Q(s_i,a_i;\theta) を最小化する方向に学習率 r_{\text{learn}} で更新(損失関数には Huber 損失関数を
16:
     用いる.)
17:
               if (t-1)\% f_{\text{update}} = 0 then
18:
                  Q^- = Q
19:
20:
               end if
            end if
21:
```

2 Atari Games の環境のラップ処理

t = t + 1

end while

24: end while

22:

Deep Q Network では Atari Games から受け取った状態の前処理などを行うことで学習をしやすくしている. 以下にそれらの処理を示す. なお、 $reset_{hoge}()$ は環境をリセットするときに呼ぶメソッドを、 $step_{hoge}(a_t)$ は行動 a_t を取って環境を更新するときに呼ぶメソッドを、 $observe_{hoge}()$ は環境の状態を返すときに呼ばれるメソッドを、 $reward_{hoge}()$ は報酬を返すときに呼ばれるメソッドを表す.

$\overline{\textbf{Algorithm 2}} \ \overline{rese} t_{\text{noop}}()$

Input: env, l_{nomax}

- 1: エピソードの開始時に,数フレーム何もしない行動を取り,初期状態を決定する.
- 2: $T \sim U(1, l_{\text{nomax}})$
- 3: **for** $t' = 1, \dots, T$ **do**
- 4: $a_{t'} = (do nothing) の実行$
- 5: end for

Output: 初期状態が決定した環境 env

Algorithm 3 $step_{repeat}(a_t)$

Input: env, l_{repeat}, a_t

- 1: 1回行動を取ると、同じ行動を指定フレーム続ける. 指定数分行動を繰り返したら、直前のフレームの観測との最大値を状態として返す.
- 2: ※ a_t は選択したい行動とする.
- 3: $r_{\text{total}} = 0$
- 4: **for** $t' = 1, \dots, l_{\text{repeat}}$ **do**
- 5: $s_{\text{prev}} = s_{t'}$
- 6: $a_{t'}=a_{t}$ として行動を選択し、環境 env を更新、 $(s_{t'+1},r_{t'},done_{t'})$ を観測する.
- 7: $r_{\text{total}} = r_{\text{total}} + r_{t'}$
- 8: $s_{\text{max}} = \max(s_{\text{prev}}, s_{t'+1})$
- 9: $done = done_{t'}$
- 10: end for

Output: $s_{\text{max}}, r_{\text{total}}, done$

Algorithm 4 observe_{gray}84()

Input: s_t

- 1: 観測した画面を (84,84) サイズのグレースケール画像に変換して返す.
- 2: s_t をグレースケール画像に変換
- 3: 変換後の s_t をさらに (84,84) に reshape

Output: 変換後の s_t

$\overline{\textbf{Algorithm 5}} \ step_{\text{stack}}(a_t)$

Input: env, l_{history} , a_t , S

- 1: l_{history} ステップ数分の観測の履歴を状態として返す.
- 2: S は観測の履歴とする.
- $3: a_t$ を行動として選択し、環境 env を更新、 $(s_{t+1}, r_t, done_t)$ を観測する.
- $4: S \subset S_{t+1}$ を追加. $|S| > l_{\text{history}}$ なら、一番古い履歴を S から削除する.

Output: $S, r_t, done_t$

Algorithm 6 reward_{clip}()

$\overline{\textbf{Input: } r_t}$

- 1: 報酬 r_t が正なら +1 に、負なら -1 に、0 なら 0 として返す。
- 2: **if** $r_t > 0$ **then**
- 3: $r_t = 1$
- 4: **else if** $r_t < 0$ **then**
- 5: $r_t = -1$
- 6: else
- 7: $r_t = 0$
- 8: **end if**

Output: r_t